

A Integração de Séries Temporais e Dados de Textos para a Previsão de Preços Futuros de Milho e Soja

Ivan J. Reis Filho¹, Leonardo V. Barcelos¹, Cicero M. Oliveira¹,
Sérgio C. Portari Júnior¹, Geraldo N. Corrêa¹

¹Sistemas de Informação – Universidade do Estado de Minas Gerais (UEMG) –
Frutal-MG-Brasil

{ivan.filho, leonardo.barcelos, cicero.oliveira, sergio.portari, geraldo.correa@uemg.br}

Abstract. *Agricultural commodities' prices perform an important role in the global market. Hence to the non-linear and non-stationary temporal series data nature, the price prediction has become a challenge. Many existing forecasting models do not take market sentiment, political events, and economic crises into account. To overcome the limitations described and motivated by the fact that agribusiness related news may have useful forecast information, text mining techniques were applied to add extracted text data and incorporate these data into two agricultural commodities temporal series. Machine learning algorithms with different arrangements were used in soybean and corn price forecasting. Four statistics evaluation techniques were applied to verify the proposed approach effectiveness. Results presented that the implemented model enhances future price forecasts. Thus, data text information offers an alternative for better and enhanced accuracy for price prediction.*

Resumo. *Os preços das commodities agrícolas desempenham um papel importante no mercado global. Assim, para a natureza dos dados das séries temporais não lineares e não estacionárias, a previsão de preços tornou-se um desafio. Muitos modelos de previsão existentes não levam em conta o sentimento do mercado, os eventos políticos e as crises econômicas. Para superar as limitações descritas e motivadas pelo fato de que as notícias relacionadas ao agronegócio podem ter informações úteis de previsão, técnicas de mineração de texto foram aplicadas para adicionar dados de texto extraídos e incorporar esses dados em duas séries temporais de commodities agrícolas. Algoritmos de aprendizagem de máquina com diferentes arranjos foram utilizados na previsão de preços de soja e milho. Quatro técnicas de avaliação estatística foram aplicadas para verificar a eficácia da abordagem proposta. Os resultados apresentados que o modelo implementado melhora as previsões futuras de preços. Assim, as informações de texto de dados oferecem uma alternativa para uma melhor e aprimorada precisão para a previsão de preços.*

1 Introdução

As commodities de milho e soja alimentam grande parte da população mundial direta ou indiretamente [2], o que fortalece a interação entre os preços do mercado de grãos de

alimentos e sua situação de oferta-demanda até certo ponto. Além disso, desempenham um papel extremamente importante nos Estados Unidos, Brasil e China, que são as três principais economias do mundo no que diz respeito ao consumo e importação dessas commodities.

Em 2016, segundo a Agência de Estatística Corporativa da Organização das Nações Unidas para Alimentação e Agricultura, *Food and Agriculture Organization Corporate Statistical Database* (FAOSTAT) [13], o Brasil é o segundo maior produtor de soja. O agronegócio brasileiro é responsável por uma quantidade considerável do produto interno bruto do país, apresentando a importância de uma melhor gestão da produção de commodities no setor. Buscando um melhor controle em grandes plantações de culturas e melhores estratégias de mercado muitos algoritmos de aprendizagem de máquina têm sido aplicados.

O mercado de commodities é conhecido por ser uma área complexa, dinâmica e não linear. Vários aspectos podem influenciar a posição dos investidores, incluindo eventos políticos, expectativas dos investidores, crise econômica, política macroeconômica governamental, oscilação do mercado externo, desastres naturais, fusões ou aquisições de grandes empresas, entre outros. A tendência do mercado é uma variação que deve ser levada em conta.

Algoritmos de aprendizado de máquina têm sido usados em uma vasta área de negócios, auxiliando na elaboração de novas estratégias para aumentar a margem de lucro. Na produção agrícola, sua aplicação varia de análise da previsão do tempo, umidade do solo, previsão de preços e outros exemplos. Assim, menos resíduos na lavoura podem ser alcançados e gerar maiores lucros [15][5][30].

Este trabalho tem como principal objetivo analisar a previsão de preços da soja e do milho utilizando algoritmos de regressão avaliados em combinação com a mineração de texto, para melhor previsão. Este artigo é organizado da seguinte forma: A Seção 3 descreve o material e os métodos utilizados na pesquisa. A Seção 4 aborda o experimento feito e a Seção 5 as considerações finais e conclusões finais.

2 Materiais e Métodos

Nesta seção é introduzido o fluxo de trabalho do experimento. A primeira subseção descreve a seleção e a descrição dos dados. A segunda subseção apresenta o procedimento experimental e a configuração. A terceira subseção retratam a pré-colocação de dados. A quarta subseção descreve os critérios de avaliação estatística, e a quinta subseção ilustra o procedimento do experimento.

2.1 Seleção e Descrição de Dados

Para iniciar o experimento, a soja e o milho foram escolhidos para comparar o desempenho entre diferentes modelos de previsão. A fonte de dados de séries temporais neste experimento foi obtida a partir de **Estimativas Mundiais de Oferta Agrícola e Demanda**, **World Agricultural Supply and Demand Estimates (WAOB)**, do

Departamento de Agricultura dos Estados Unidos, disponível no site kaggle¹. A Tabela 1 descreve o período e o tamanho dos conjuntos de dados.

Tabela 1. Período e duração dos dois preços futuros

Commodities	Período	Meses	Número de atributos
Milho	Jan 2014 a Feb 2020	73	70
Soja	Jan 2014 a Feb 2020	73	112

A tabela descreve a coleta de dados que varia de janeiro de 2014 a fevereiro de 2020. O número de atributos representa os seguintes exemplos, área plantada, área colhida, rendimento, estoques incorrendo, importações, oferta, demanda e outras estimativas de países com maior produção de milho e soja. Os preços originais são obtidos na *Chicago Board of Trade (CBOT)*, que está disponível no site do *CME-Group*². O CBOT é um fabricante de contratos designado para o CME Group para futuras trocas onde os contratos de commodities agrícolas são negociados, e os preços cobrados na CBOT são uma referência no preço mundial. Os números 1 e 2 ilustram o gráfico de sequência da média mensal, mediana e valor de milho e soja para o sétimo dia útil de cada mês (dia do relatório waob). O menor preço do milho por bushel foi de US\$ 3,22 em agosto de 2016, enquanto o maior foi de US\$ 5,07 em maio de 2014, e a variação entre os preços mais altos e os mais baixos superou 30%. O menor preço da soja por bushel foi de US\$ 8,09 em junho de 2019, enquanto o maior foi de US\$ 14,85 em abril de 2014, e a variação entre os preços mais altos e os mais baixos superou 45%. Neste trabalho, considerou-se o valor da média mensal para prever o preço futuro do milho e da soja.




Fig.1. Preço histórico do milho de 2014 a 2020.

¹ <https://www.kaggle.com/ainslie/usda-wasde-monthly-corn-soybean-projections>

² <http://www.cmegroup.com/>




Fig.2. Preço histórico da soja de 2014 a 2020.

Para a análise do experimento de correlação, os dados textuais foram extraídos do site Soja & Corn Advisor³. Desde 2009, o site fornece diariamente notícias e informações sobre a produção de soja e milho, relacionadas aos ciclos de crescimento da América do Sul, clima, infraestrutura, uso da terra, etanol e produção de combustíveis alternativos. As próximas seções explicam a configuração dos experimentos neste trabalho.

2.2 Pré-processamento de dados

A avaliação-chave deste estudo é combinar dados de textos e séries temporais para prever o preço futuro do milho e da soja utilizando técnicas de mineração de texto. A seleção de recursos é uma das principais questões da literatura de mineração de texto, e existem muitos métodos disponíveis para a seleção de recursos. Um dos métodos mais comuns é aplicar uma representação vetorial onde os termos são indexados e ponderados. O tipo de representação mais popular na literatura de representação de texto é conhecido como técnica de "bag-of-words" (BoW) [21] apud [31].

Neste estudo, cada texto (T_t) é representado utilizando a técnica "bag-of-words", que representa dados textuais como vetores de características. Esta representação identifica os termos mais importantes e cada recurso corresponde a um componente do vetor [17] apud [31]. Os termos extraídos do texto são representados em pesos especificados com frequência de termo (TF) ou frequência de frequência de termo – frequência inversa medida [25] apud [31].

Assumimos que a série temporal é $Y = \{y_1, \dots, y_t, \dots, y_n\}$ e o conjunto de dados textuais $T = \{T_1, \dots, T_t, \dots, T_N\}$, onde y_t e T_t são o valor e o texto disponível no momento t , respectivamente, sendo N o número de observações amostrais em T . O peso TF-IDF $x_{i,t}$ para o termo k_i em T_t é definido por

$$x_{i,t} = TF_{i,t} * IDF_i \quad (1)$$

onde $TF_{i,t}$ representa a frequência normalizada do termo k_i no texto T_t , IDF_i representa a frequência de documentos inversos. Assim, os dados textuais (T_t) são representados como um vetor $X_t = (x_{1,t}, \dots, x_{i,t}, \dots, x_{V,t})$, onde V é o tamanho do vocabulário. Neste trabalho,

³ <http://www.soybeansandcorn.com>

concatenamos os dados da série temporal e os dados do BoW para prever o preço da soja e do milho, expressos como:

$$S_t = [Y_t | X_t] \quad (2)$$

onde Y_t é o vetor com dados de séries temporais nas hipóteses t de dimensão mn , e X_t é o vetor de dados textuais no momento t de dimensão mv [31]. Na próxima subseção, são apresentados testes estatísticos utilizados para avaliar o desempenho da previsão.

2.3 Procedimento experimental e configuração

As séries de tempo financeiro e os dados de texto estão em constante mudança e são frequentemente influenciados por fatores externos (climáticos, financeiros, políticos, entre outros). Modelos preditivos dificilmente usam janelas grandes para a fase de treinamento para generalizar ou aprender o modelo de aprendizagem. Por isso, para avaliar o modelo proposto, utilizamos o método de janela deslizante para as fases de aprendizagem (treinamento) e validação (teste). Foram realizados experimentos com janelas deslizantes entre 2 e 48 meses para treinamento e 1 mês para testes.

Para avaliar os efeitos preditivos do modelo proposto, três algoritmos foram aplicados com parâmetros diferentes. A Função de Base Radial (RBF), a função Sigmoid e a Regressão Polinomial⁴ são atribuídas como modelos de comparação para prever os preços dos futuros de commodities.

Durante a implementação do BoW, as palavras de parada⁵ são excluídas e os parâmetros são atribuídos com $\min = 1\%$, $\max = 90\%$ e $\text{grama} = 2$. Os valores de \min e \max são limiares que eliminam termos e tokens BoW inferiores a 1% e maiores que 90% de frequência no texto, respectivamente. A representação de duas sequências de elementos adjacentes (palavras) é definida pelo parâmetro $\text{gram} = 2$.

2.4 Critérios de Avaliação Estatística

Para avaliar a validade e o desempenho da previsão do modelo proposto, foram utilizados indicadores estatísticos e testes estatísticos. Os quatro índices de erro geralmente adotados são: Erro Absoluto Médio, *Mean Absolute Error* (MAE), Erro percentual absoluto médio, *Mean Absolute Percentage Error* (MAPE), Erro médio do quadrado, *Mean Square Error* (MSE) e Erro quadrado de média raiz, *Root Mean Square Error* (RMSE), apresentados na Tabela 2.

⁴ <https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVR.html>

⁵ Preposições, conjunções e artigos são removidos.

Tabela 2. Equações de Avaliação Estatística

$MAE = (\frac{1}{n}) \sum_{i=1}^n y_i - x_i $	$MAPE = \frac{1}{n} \sum_{t=1}^n \left \frac{y_i - x_i}{x_i} \right $
$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - x_i)^2$	$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - x_i)^2}$

Para as equações apresentadas na Tabela 3, n é o número de amostras de teste, $x(i)$ é o dado real de cada conjunto de dados, e $y(i)$ é o valor de previsão dos dados de preços futuros correspondentes.

3 Avaliação experimental

Nesta seção, as avaliações experimentais são descritas utilizando-se sete modelos de regressão para analisar o desempenho da previsão. Posteriormente, são apresentados resultados de análise de erros e testes estatísticos.

3.1 Resultados

Para realizar este experimento, foram aplicados sete janelas de tamanho para analisar a previsão de preços para milho e soja. À medida que o tamanho das janelas foi aumentado (treinamento), o número de testes foi reduzido. Para cada janela, o resultado mostrado é a melhor média de desempenho. A Tabela 3 apresenta os resultados da previsão do preço do milho utilizando apenas dados de séries temporais. A Tabela 4 demonstra os resultados do desempenho da previsão usando dados de séries tempordicais e dados de texto. O "Treinamento" é a quantidade de meses utilizados para o treinamento Grupo. "Modelo" é o algoritmo com o melhor desempenho de previsão (média) para sua respectiva janela.

Tabela 3. Previsão do Preço do Milho - Série Temporal

Treinamento	Modelo	Mae	Mse	RMSE	Mape
2	Modelo 2	0.17	0.06	0.17	4.57 %
3	Modelo 2	0.19	0.07	0.19	5.07 %
6	Modelo 2	0.19	0.07	0.19	5.22 %
12	Modelo 7	0.14	0.03	0.14	3.84 %
24	Modelo 2	0.14	0.03	0.14	3.81 %
36	Modelo 2	0.13	0.03	0.13	3.49 %
48	Modelo 2	0.13	0.04	0.13	3.48 %

Tabela 4. Previsão do Preço do Milho - Séries Temporais e Dados de Texto

Treinamento	Modelo	Mae	Mse	RMSE	Mape
2	Modelo 2	0.17	0.06	0.17	4.49 %
3	Modelo 2	0.18	0.07	0.18	4.91 %
6	Modelo 2	0.18	0.06	0.18	4.92 %
12	Modelo 2	0.13	0.03	0.13	3.70 %
24	Modelo 2	0.13	0.03	0.13	3.61 %
36	Modelo 2	0.12	0.03	0.12	3.24 %
48	Modelo 2	0.12	0.03	0.12	3.23 %

A Tabela 5 apresenta o desempenho de previsão para o preço da soja. Para prever, foi usado apenas dados de séries temporais. Os resultados da Tabela 6 mostram o desempenho de previsão usando dados de séries temporais e dados extraídos de textos.

Tabela 5. Previsão do Preço da Soja - Série Temporal

Treinamento	Modelo	Mae	Mse	RMSE	Mape
2	Modelo 7	0.45	0.43	0.45	4.44 %
3	Modelo 2	0.52	0.61	0.52	5.17 %
6	Modelo 7	0.52	0.64	0.52	5.20 %
12	Modelo 7	0.45	0.39	0.45	4.79 %
24	Modelo 5	0.51	0.42	0.51	5.57 %
36	Modelo 7	0.46	0.36	0.46	5.08 %
48	Modelo 7	0.35	0.21	0.35	3.90 %

3.2 Discussão

De acordo com os resultados da Tabela 4 e 5 relacionados à previsão de preço do milho, o algoritmo "modelo 2" tem o melhor desempenho de previsão na maioria das avaliações. Analisando ambos os resultados para as respectivas janelas, as métricas MAE, MSE e RMSE apresentam resultados semelhantes, diferindo de 0,01 e 0,03 centavos de dólar. O MAPE difere de 0,08% (treinamento 2) e 0,30% (treinamento 6). Tabela 5 janela de treinamento de 48 meses pontua o melhor desempenho de previsão em perspectiva para todos os outros resultados. Os resultados mostram que uma janela de treinamento maior tem melhor desempenho de previsão.

Tabela 6. Previsão do Preço da Soja - Séries Tempoes e Dados de Texto

Treinamento	Modelo	Mae	Mse	RMSE	Mape
2	Modelo 2	0.43	0.40	0.43	4.31 %
3	Modelo 2	0.47	0.53	0.47	4.75 %
6	Modelo 2	0.50	0.72	0.50	5.20 %
12	Modelo 2	0.42	0.33	0.42	4.50 %
24	Modelo 2	0.37	0.24	0.37	4.04 %
36	Modelo 2	0.43	0.30	0.43	4.77 %
48	Modelo 7	0.41	0.27	0.41	4.59 %

Em comparação com os resultados previstos relacionados ao milho nas Tabelas 5 e 6, os modelos 2 e 7 tiveram os melhores desempenhos para a maioria das avaliações. Analisando ambos os resultados para as respectivas janelas, a MAPE apresenta uma diferença de 0,13% (treinamento 2) e 1,69% (treinamento 48). Métricas MAE, MSE e RMSE apresentam resultados de intervalo mais elevados se comparados ao milho. Analisando todos os resultados, a janela de treinamento de 48 meses da Tabela 5 teve o melhor desempenho de previsão.

No geral, os resultados do milho apresentam melhor desempenho quando comparados com os resultados da soja. A commodity de milho oferece mais atributos de série temporal do que a soja, e a base textual do milho oferece menos informações de texto em comparação com a soja. Após analisar a dimensão integrada dos dados (série e texto), foi possível concluir que a matriz de atributos do milho, no que diz respeito à sua dimensionalidade, era menor e menos esparsa que a soja. Por essa razão, os resultados de previsão de milho tiveram os melhores desempenhos.

4 Conclusões

Os modelos híbridos mostraram um aumento de precisão nas previsões do mercado financeiro. Muitos modelos existentes não levam em conta fatores externos, como sentimento de mercado, condições climáticas, aspectos políticos e outros. Para superar essas limitações, e motivado pela evidência de que as notícias agrícolas contêm algumas informações de previsão, este trabalho propôs uma integração de séries temporais e dados de texto para prever o preço de duas commodities agrícolas.

Técnicas de mineração de texto foram utilizadas para construir a matriz de atributos de valor (BoW) e concatenar com dados de séries temporais. O modelo proposto foi avaliado utilizando-se a técnica de janela deslizante e sete modelos de aprendizado de máquina foram aplicados para prever os preços futuros do milho e da soja, analisando diferentes períodos de treinamento e teste.

Os resultados experimentais mostraram que o modelo proposto melhora o desempenho da previsão em comparação com o modelo que utilizou apenas séries de

tempos de dados. Isso indica que as informações textuais fornecem uma alternativa para melhorar a precisão das previsões de preços das commodities agrícolas.

Trabalhos recentes na mineração de textos mostram melhor desempenho considerando aspectos semânticos. Em relação a isso, para reduzir nossa dimensionalidade modelo e dados esparsos, podemos incorporar aspectos semânticos em tarefas de regressão, buscando termos mais significativos e selecionar os atributos mais representativos.

Referências

1. Adanacioglu, H., Yercan, M.: Uma análise dos preços do tomate a nível atacado na Turquia: uma aplicação do modelo SARIMA. In: Custos e agronegócio on line, vol. 8, n. 4, pp. 52 – 75 (2012).
2. Ahumada, H., Cornejo, M.: Previsão dos preços dos alimentos: O caso do milho, da soja e do trigo. In: International Journal of Forecasting, vol. 32, n. 3, pp. 838-848 (2016).
3. Alameer, Z., Elaziz, M. A., Ewees, A.A., Ye, H., Jianhua, Z.: Prever flutuações de preço do ouro usando rede neural perceptron multicamadas melhorada e algoritmo de otimização de baleias. In: Política de Recursos, vol. 61, pp. 250-260 (2019).
4. Barun'ik, J., Malinska', B.: Prever o termo estrutura dos preços futuros do petróleo bruto com redes neurais. In: Energia aplicada, vol. 164, pp. 366-379 (2016).
5. Bitvai, Z., Cohn, T.: Maximização do lucro do day trading com aprendizado multitarefa e análise técnica. Mach. Aprenda. 101, 1-3, 187-209 (2015).
6. Brownlee, J.: Métodos Estatísticos para Machine Learning: Descubra como transformar dados em conhecimento com Python. In: Machine Learning Mastery (2018).
7. Chen, H. H., Chen, M., Chiu, C. C.: A integração de redes neurais artificiais e mineração de texto para prever os preços futuros do ouro. In: Comunicações em Estatística-Simulação e Computação, vol. 45, n. 4, pp. 1213-1225 (2016).
8. Crone, S. F., Koepfel, C.: Prever taxas de câmbio com indicadores de sentimento: Uma avaliação empírica usando mineração de texto e perceptrons multicamadas. In: 2014 IEEE Conference on Computational Intelligence for Financial Engineering & Economics (CIFEr), pp. 114-121. IEEE (2014).
9. Darekar, A., Reddy, A.: Prever o preço de mercado da soja nos principais estados da Índia através do modelo ARIMA. In: Journal of Food Legumes, vol. 30, n. 2, pp. 73-76 (2017).
10. Das, S. P., Padhy, S.: Um novo modelo híbrido usando otimização baseada em ensino-aprendizagem e uma máquina vetorial de suporte para previsão de índices futuros de commodities. In: International Journal of Machine Learning and Cybernetics, vol. 9, n. 1, pp. 97-111 (2018).
11. Draper, N.R., Smith, H.: Análise de regressão aplicada. John Wiley & Sons (1998)

12. Fegade T.K., Pawar B.V.: Previsão de culturas usando rede neural artificial e máquina vetorial de suporte. In: Sharma N., Chakrabarti A., Balas V. (eds) Data Management, Analytics e Innovation. Avanços em Sistemas Inteligentes e Computação, vol. 1016. Springer, Cingapura (2020).
13. FAOSTATS, <http://www.fao.org/faostat/en/#data/QC/>. O último acesso foi em 30 abr 2020.
14. Fung, G. P. C., Yu, J. X., Lam, W.: Previsão de estoque: Integrando abordagem de mineração de texto usando notícias em tempo real. In: 2003 IEEE International Conference on Computational Intelligence for Financial Engineering, pp. 395-402. Processo. IEEE (2003).
15. Hand, D.J., Blunt, G., Kelly, M. G., Adams, N. M.: Mineração de dados por diversão e lucro. In: Statistical Science, vol. 15, n. 2, pp. 111-131 (2000).
16. Jiang, F., He, J., Zeng, Z.: Otimização inspirada em pombos e máquina de aprendizagem extrema através da análise de pacotes de wavelet para prever os preços futuros de commodities a granel. In: Science China Information Sciences, vol. 62, n. 7, pp. 70204 (2019).
17. Joachims, T.: Categorização de texto com máquinas vetoriais de suporte: Aprender com muitas características relevantes. In: Conferência Europeia sobre machine learning, pp. 137-142. Springer, Berlim, Heidelberg (1998).
18. Johnson, D. M.: Uma avaliação das variáveis pré e dentro da estação remotamente sentidas para a previsão da produção de milho e soja nos Estados Unidos. In: Sensoriamento Remoto do Meio Ambiente, vol. 141, pp. 116-128 (2014).
19. Kanchymalay, K., Salim, N., Sukprasert, A., Krishnan, R., Hashim, U. R. A.: Série tempo multivariada prevendo o preço do óleo de palma bruto usando técnicas de aprendizado de máquina. In: IOP Conference Series Materials Science and Engineering, vol. 226, no 1. IOP Publishing (2017).
20. Kastens, J. H., Kastens, T. L., Kastens, D. L., Price, K. P., Martinko, E. A., Lee, R. Y.: Máscara de imagem para previsão de rendimento de culturas usando imagens da série temporal AVHRR NDVI.
In: Sensoriamento Remoto do Meio Ambiente, vol. 99, n. 3, pp. 341-356 (2005).
21. Marvin, S., Scott, S.: Engenharia de recursos para classificação de texto. In: Proceedings of international conference on machine learning (1999).
22. Natanelov, V., Alam, M. J., McKenzie, A. M., Van Huylenbroeck, G.: Is there comovement of agricultural commodities futures prices and crude oil?. In: Energy Policy, vol. 39, n. 9, pp. 4971–4984 (2011).
23. Puchalsky, W., Ribeiro, G. T., da Veiga, C. P., Freire, R. Z., dos Santos Coelho, L.: Agribusiness time series forecasting using Wavelet neural networks and metaheuristic optimization: An analysis of the soybean sack price and perishable products demand. In: International Journal of Production Economics, vol. 203, pp. 174–189 (2018).
24. Ramírez, S. C., Arellano, P. L. C.; Rojas, O.: Adaptive market efficiency of agricultural commodity futures contracts. In: Contaduría y Administración, vol. 60, n. 2, pp. 389–401 (2015).

25. Salton, G.: Automatic text processing: The transformation, analysis, and retrieval of. Reading: Addison-Wesley, 169 (1989).
26. Seber, G. A. F., Lee, A. J.: Linear regression analysis. vol. 329. John Wiley & Sons (2012)
27. Shakoor, M. T., Rahman, K., Rayta, S. N., Chakrabarty, A.: Agricultural production output prediction using supervised machine learning techniques. In: 1st International Conference on Next Generation Computing Applications (NextComp) 2017, pp. 182–187. IEEE (2017).
28. Tian, F., Yang, K., Chen, L.: Realized volatility forecasting of agricultural commodity futures using the HAR model with time-varying sparsity. In: International Journal of Forecasting, vol. 33, n. 1, pp. 132–152 (2017).
29. Tokgoz, S., Wailes, E., Chavez, E.: A quantitative analysis of trade policy responses to higher world agricultural commodity prices. In: Food Policy, vol. 36, n. 5, pp. 545–561 (2011).
30. Tsai, C.-F., Chen, M.-L.: Credit rating by hybrid machine learning techniques. Appl. Soft Comput. 10, 2, 374–380 (2010).
31. Wang, B., Huang, H., Wang, X.: A novel text mining approach to financial time series forecasting. In: Neurocomputing, vol. 83, pp. 136–145 (2012).
32. Wang, D., Yue, C., Wei, S., Lv, J.: Performance analysis of four decomposition-ensemble models for one-day-ahead agricultural commodity futures price forecasting. In: Algorithms, v. 10, n. 3, pp 108 (2017).
33. Wang, C., Gao, Q.: High and Low Prices Prediction of Soybean Futures with LSTM Neural Network. In: 2018 IEEE 9th International Conference on Software Engineering and Service Science (ICSESS), pp. 140–143. IEEE 2018.
34. Xiong, T., Li, C., Bao, Y., Hu, Z., Zhang, L.: A combination method for interval forecasting of agricultural commodity futures prices. In: Knowledge-Based Systems, vol .77 , pp. 92–102 (2015).
35. Zhang, Y., He, J., Yin, T. F.: Research on petroleum price prediction based on SVM. In: Computer Simulation, vol. 3, pp. 93 (2012).
36. Zhang, D., Duan, H., Yang, Y.: Active disturbance rejection control for small unmanned helicopters via Levy flight-based pigeon-inspired optimization. In: Aircraft Engineering and Aerospace Technology (2017).
37. Zhang, D., Zang, G., Li, J., Ma, K., Liu, H.: Prediction of soybean price in China using QR-RBF neural network model. In: Computers and Electronics in Agriculture, vol. 154 , pp. 10–17 (2018).
38. Zou, H. F., Xia, G. P., Yang, F. T., Wang, H. Y.: An investigation and comparison of artificial neural network and time series models for Chinese food grain price forecasting. In: Neurocomputing, vol. 70, n. 16, pp. 2913–2923 (2007).